

DESAFIO AI ENGINEER

# Contas a pagar que chegam por e-mail

Uma POC que captura cobranças, extrai os dados e — onde há dinheiro em jogo — confere em vez de confiar.

48 e-mails reais

0 erros

US\$ 0,36

O PROBLEMA

# Um LLM erra de um jeito perigoso

Ele não erra devolvendo lixo. Ele erra devolvendo algo plausível — e plausível ninguém confere.

O MODELO LEU

R\$ 987,00

Uma casa decimal a menos. O número existe, a formatação é válida, o fornecedor é o certo.

O BOLETO DIZ

R\$ 9.870,00

O fornecedor não recebe. A conta vence. A multa chega semanas depois.

⚠ Numa fila de 200 contas, ninguém confere as que parecem certas. É por isso que confiança sozinha não resolve.

# Valor e vencimento não precisam ser lidos

Eles estão aritmeticamente codificados na própria linha digitável.

34191.79001 01043.510047 91020.150008 1 15700000123456

FATOR DE VENCIMENTO

Fator 1570 desde a data-base → 15/09/2026

VALOR EM CENTAVOS

123456 centavos → R\$ 1.234,56



Quatro dígitos verificadores — três mod 10 e um mod 11 geral — provam que a linha não foi transcrita errada



O mesmo vale para CNPJ, chave da NF-e e Pix — todos têm verificação própria



O LLM lê. A aritmética confere. Se discordam, ninguém decide sozinho.

# Três abordagens, e por que a terceira

A

## Determinística

Regex e um template por fornecedor.

+ Barata, auditável, zero alucinação

– Cada fornecedor novo vira fila de engenharia

B

## LLM ponta a ponta

PDF direto para o modelo, com saída estruturada.

+ Cobre layout nunca visto no dia 1

– Sem piso justo onde errar custa mais

C

## Híbrida

LLM para cobertura, aritmética como porteiro.

Absorve fornecedor novo sem deploy

E tem piso onde o erro custa

*"Fase inicial; as necessidades podem evoluir rapidamente com novos clientes."*


A abordagem A não escala nisso — cada cliente traz fornecedores novos.

*"Errar valor ou vencimento tem custo."*

A abordagem B sozinha não tem piso. A C tem, e ele cobre exatamente esses campos.

# Seis etapas, e a ordem importa

A triagem vem antes da extração porque abrir PDF no modelo caro é o item mais caro do fluxo — e caixa real é majoritariamente ruído.



TRÊS CAMINHOS DE EXTRAÇÃO

1. XML da NF-e, sem LLM · 2. Varredura da linha digitável no texto, validada por DV · 3. LLM com o PDF nativo

# Cada campo diz de onde veio



## Conferido por aritmética

Código de barras, XML da NF-e, chave, Pix. Confiança 1.0 por construção.



## Lido pelo modelo

Vem com confiança declarada e o trecho verbatim onde leu.



## Corrigido por humano

A leitura do modelo não é apagada — fica auditável.



## Histórico do fornecedor

Recorrência e categoria que o documento isolado não revela.

A POLÍTICA MORA EM CÓDIGO, NÃO NO PROMPT

```
auto_ok → triagem confiante
        ∧ checksums fecham
        ∧ valor(LLM) = valor(barras)
        ∧ CNPJ válido ∧ não é duplicata
```

```
revisar → falhou qualquer um acima
```

```
ruído → gravado com o motivo
```

---

**Aritmética vence leitura, sempre.** Mas a divergência nunca se resolve em silêncio.

**Nada paga sozinho** — faixa rápida é posição na fila, não autorização.

# Dois mundos, perguntas diferentes

O payable vira "pago" e some da tela. A trilha de como aquele valor foi parar ali precisa sobreviver.

MUNDO ERP · MUTÁVEL

"O que eu tenho a pagar?"

|                     |                           |
|---------------------|---------------------------|
| payables            | o registro central        |
| vendors             | fornecedor, por CNPJ      |
| payment_instruments | linha digitável, Pix      |
| payment_schedules   | o agendamento no banco    |
| recurrence_groups   | cadência e valor esperado |

MUNDO AUDITORIA · APPEND-ONLY

"Por que o sistema acha isso?"

|                    |                               |
|--------------------|-------------------------------|
| email_messages     | o e-mail que chegou           |
| processing_steps   | custo, tokens, prompt_version |
| classifications    | a triagem, inclusive do ruído |
| field_extractions  | a espinha dorsal              |
| validation_results | esperado × encontrado         |
| review_actions     | quem mudou o quê              |

field\_extractions responde, para qualquer número na tela: **de onde veio, com que confiança, e qual trecho do documento sustenta**. É o que distingue um valor conferido de um valor lido — e é a distinção que a UI inteira usa.

# Três telas, na ordem do trabalho

O sistema não paga. Ele registra que um humano pagou — com banco, data e protocolo.



## Caixa de entrada

Três faixas: Revisar, Pronto e Ruído. Urgente primeiro, depois por número de bloqueios.

O ruído fica visível com o motivo. Descartar em silêncio cria um falso negativo que ninguém descobre.



## Revisão

Documento à esquerda, campos à direita. Cada campo com o selo de origem e a evidência.

Sem essa distinção o revisor confere tudo com o mesmo cuidado — que é o mesmo que não conferir.



## Agenda

Agrupada por vencimento. Copia a linha digitável, paga no banco, volta e registra o protocolo.

Ou exporta CNAB 240 e agenda o lote inteiro de uma vez.



O agendamento bancário continua manual e fora do sistema. O protocolo que volta é o que permite reconciliar depois.

# Não é demo com dado fabricado

48

e-mails processados

88%

ruído descartado

0

erros

US\$ 0,36

custo total

## ACURÁCIA NO CONJUNTO ROTULADO

Triagem 16 / 16

Valor 4 / 4

Vencimento 5 / 5

---

Cobranças perdidas **nenhuma**

## O QUE SÓ A CAIXA REAL ENSINOU

Todas as cobranças chegam encaminhadas da mesma pessoa — o remetente real está no corpo

Dois dos seis PDFs vêm com senha. Num deles a linha digitável estava no corpo, e a varredura resolveu

O mesmo provedor com dois nomes — por isso o casamento é por CNPJ, nunca por nome

# Limitações e o que viria a seguir

## Limitações da POC

Uma caixa só, e por polling

PDF protegido por senha não é aberto — dois dos seis boletos reais são assim

Sem OCR dedicado para foto ruim

Write-back em ERP só por arquivo, não pela API

CNAB no layout FEBRABAN genérico, sem homologação por banco

## O que quebra em escala

OAuth por caixa não escala. O caminho é um endereço de encaminhamento por cliente — funciona em qualquer provedor

Polling vira watch + Pub/Sub

Custo: Batch API no backfill e prompt caching

Multi-tenant: org\_id já está em tudo, falta ligar RLS

## O que eu faria a seguir

Aprender template por fornecedor a partir das correções humanas.

A tabela review\_actions é o sinal de treino: depois de N extrações confirmadas do mesmo remetente e layout, promover para parser determinístico e tirar aquele fornecedor do caminho do LLM.

---

O custo cai e a confiança sobe com o uso — a curva certa para um produto que ganha clientes.

oi **Bill** ✓✓

TESTE AO VIVO

Com os 48 e-mails reais já processados

**bill-poc.vercel.app**

O botão **Buscar novos e-mails** lê a caixa ao vivo pela Gmail API e processa o que ainda não foi visto — um e-mail por vez, com progresso na tela.

REPOSITÓRIO

[github.com/PauloRbtoCodes/bill-poc](https://github.com/PauloRbtoCodes/bill-poc)

STACK

Python · Next.js · Postgres no Supabase · Vercel

